

Reverse-Mode 自動微分を理解する

Hiromi ISHII

2023-03-15

Tsukuba Computer Mathematics Seminar 2023

Forward-Mode と Reverse-Mode 自動微分

Forward-Mode と Reverse-Mode 自動微分

自動微分とは？

- ◆ **自動微分**：与えられた関数の値とその微分係数を，合成関数の微分公式（連鎖律）を使って効率的・厳密に計算する方法
 - ▶ 関数の値を順に計算しながら、連鎖律を使って微分係数も計算する
- ◆ 関連するが異なる計算方法：
 - ▶ **記号微分**：数式を記号的な構文木で表現し，微分法則に従い記号的に処理。
 - 厳密だが項数が組合せ爆発して非効率になりがち。
 - ▶ **数値微分**：極限 $\lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$ の Δx を微小数で置き換えて近似。
 - あくまで近似。 Δt をどう近似するかで振る舞いが変わってくる。

連鎖律

◆ 皆さんお馴染の基本公式

$$\mathbb{R}^n \xrightarrow{f} \mathbb{R}^k \xrightarrow{g} \mathbb{R}^m$$

$$\frac{d}{d\mathbf{x}}(g \circ f) = \frac{dg}{df} \frac{df}{d\mathbf{x}}$$

- ◆ 統一性のため $\mathbf{u}_0 = \mathbf{x}, \mathbf{u}_1 = f(\mathbf{u}_0), \mathbf{u}_2 = g(\mathbf{u}_1) = g(f(\mathbf{u}_0))$ として並び換えれば,

$$\mathbb{R}^m \xleftarrow{\mathbf{u}_2} \mathbb{R}^k \xleftarrow{\mathbf{u}_1} \mathbb{R}^n \xleftarrow{\mathbf{u}_0} \mathbb{R}^0$$

$$\frac{d\mathbf{u}_2}{d\mathbf{u}_0} = \frac{d\mathbf{u}_2}{d\mathbf{u}_1} \frac{d\mathbf{u}_1}{d\mathbf{u}_0}$$

連鎖律

◆ 皆さんお馴染の基本公式

$$\mathbb{R}^n \xrightarrow{f} \mathbb{R}^k \xrightarrow{g} \mathbb{R}^m$$

$$\frac{d}{d\mathbf{x}}(g \circ f) = \frac{dg}{df} \frac{df}{d\mathbf{x}}$$

- ◆ 統一性のため $\mathbf{u}_0 = \mathbf{x}, \mathbf{u}_1 = f(\mathbf{u}_0), \mathbf{u}_2 = g(\mathbf{u}_1) = g(f(\mathbf{u}_0))$ として並び換えれば,

$$\mathbb{R}^m \xleftarrow{\mathbf{u}_2} \mathbb{R}^k \xleftarrow{\mathbf{u}_1} \mathbb{R}^n \xleftarrow{\mathbf{u}_0} \mathbb{R}^0$$

$$\frac{d\mathbf{u}_2}{d\mathbf{u}_0} = \frac{d\mathbf{u}_2}{d\mathbf{u}_1} \frac{d\mathbf{u}_1}{d\mathbf{u}_0}$$

連鎖律 (多変数)

多変数も同様 (但し、各 $\partial u_i / \partial u_j$ はヤコビ行列だということ)

$$\mathbb{R}^{n_N} \xleftarrow{u_N} \mathbb{R}^{n_{N-1}} \xleftarrow{u_{N-1}} \dots \xleftarrow{u_1} \mathbb{R}^{n_0} \xleftarrow{u_0} \mathbb{R}^0$$

$$\frac{\partial u_N}{\partial u_0} = \frac{\partial u_N}{\partial u_{N-1}} \frac{\partial u_{N-1}}{\partial u_{N-2}} \dots \frac{\partial u_2}{\partial u_1} \frac{\partial u_1}{\partial u_0}$$

連鎖律 (多変数)

多変数も同様 (但し、各 $\partial u_i / \partial u_j$ はヤコビ行列だということ)

$$\mathbb{R}^{n_N} \xleftarrow{u_N} \mathbb{R}^{n_{N-1}} \xleftarrow{u_{N-1}} \dots \xleftarrow{u_1} \mathbb{R}^{n_0} \xleftarrow{u_0} \mathbb{R}^0$$

$$\frac{\partial u_N}{\partial u_0} = \frac{\partial u_N}{\partial u_N} \frac{\partial u_N}{\partial u_{N-1}} \frac{\partial u_{N-1}}{\partial u_{N-2}} \dots \frac{\partial u_2}{\partial u_1} \frac{\partial u_1}{\partial u_0} \frac{\partial u_0}{\partial u_0}$$

連鎖律 (多変数)

多変数も同様 (但し、各 $\partial u_i / \partial u_j$ はヤコビ行列だということ)

$$\mathbb{R}^{n_N} \xleftarrow{u_N} \mathbb{R}^{n_{N-1}} \xleftarrow{u_{N-1}} \dots \xleftarrow{u_1} \mathbb{R}^{n_0} \xleftarrow{u_0} \mathbb{R}^0$$

$$\frac{\partial u_N}{\partial u_0} = \frac{\partial u_N}{\partial u_N} \frac{\partial u_N}{\partial u_{N-1}} \frac{\partial u_{N-1}}{\partial u_{N-2}} \dots \frac{\partial u_2}{\partial u_1} \frac{\partial u_1}{\partial u_0} \frac{\partial u_0}{\partial u_0}$$

← Forward

これを前から計算するのが Forward-Mode 自動微分

連鎖律 (多変数)

多変数も同様 (但し、各 $\partial u_i / \partial u_j$ はヤコビ行列だということ)

$$\mathbb{R}^{n_N} \xleftarrow{u_N} \mathbb{R}^{n_{N-1}} \xleftarrow{u_{N-1}} \dots \xleftarrow{u_1} \mathbb{R}^{n_0} \xleftarrow{u_0} \mathbb{R}^0$$

$$\frac{\partial u_N}{\partial u_0} = \frac{\partial u_N}{\partial u_N} \frac{\partial u_N}{\partial u_{N-1}} \frac{\partial u_{N-1}}{\partial u_{N-2}} \dots \frac{\partial u_2}{\partial u_1} \frac{\partial u_1}{\partial u_0} \frac{\partial u_0}{\partial u_0}$$



これを前から計算するのが Forward-Mode 自動微分

これを後から計算するのが Reverse-Mode 自動微分

Foward Mode 自動微分

- ◆ Dual Number $\mathbb{R}[d]/(d^2)$ を使って計算できる
 - ▶ $x + yd$ の y が一次微分係数を覚える役割を果す ($f(x) + f'(x)d$ と思う)
- ◆ 代数演算はそのまま延長、(区分的に) 滑らかな関数についても Weil 環の標準的な C^∞ -環構造が入る
 - ▶ 難しく聞こえるが、以下のような感じ：

$$\sin(x + yd) = \sin(x) + y\cos(x)d,$$

$$\cos(x + yd) = \cos(x) - y\sin(x)d,$$

$$e^{(x+yd)} = e^x + ye^x d$$

Forward Mode 計算例

- ◆ 次で定まる関数 $f : \mathbb{R} \rightarrow \mathbb{R}^3$ の x に関する微分を求めてみよう：

$$f(x) = (\sin(x^2 + 1), e^{x^2}, x^3 e^{-x})$$

- ◆ 入口は $x + (dx/dx)d = x + d$ を入れて $f(x + d)$ を評価してみる：

$$\begin{aligned} & f(x + d) \\ &= (\sin((x + d)^2 + 1), e^{(x+d)^2}, (x + d)^3 e^{-(x+d)}) \\ &= (\sin(x^2 + 2xd + 1), e^{x^2+2xd}, (x^3 + 3x^2d)(e^{-x} - e^{-x}d)) \\ &= (\sin(x^2 + 1) + 2x \cos(x^2 + 1)d, e^{x^2} + 2xe^{x^2}d, (x^3 + 3x^2d)(e^{-x} - e^{-x}d)) \\ &= (\sin(x^2 + 1), e^{x^2}, x^3 e^{x-x}) + \underline{(2x \cos(x^2 + 1), 2xe^{x^2}, -x^3 e^{-x} + 3x^2 e^{-x})d} \end{aligned}$$

Forward-Mode だけでいいのでは？

- ◆ 入力が一変数、出力が多変数の場合は Forward-Mode で十分効率的
- ◆ しかし、機械学習のように $f: \mathbb{R}^N \rightarrow \mathbb{R}$ で $N \gg 0$ の場合、Forward-Mode では効率がわるすぎる！
 - (a) 素朴にやると、 $\mathbb{R}[d]^N$ を用意して、 $i < N$ ごとに $(0, \dots, 0, x + d_i, 0, \dots)$ みたいなのを何回も渡すことになる
 - (b) これを組にして $(\mathbb{R}[d]^N)^N$ について一挙に計算すると one-pass
 - (c) しかしいずれにせよ変数の数について自乗のオーダーがかかってしまい非効率！
- ◆ $dx/dx = du_0/du_0$ ではなく du_N/du_N の側から辿ったらどうか？
 - ▶ これが Reverse-Mode 自動微分！

Reverse-Mode 自動微分いろいろ

Reverse-Mode 自動微分いろいろ

Reverse-Mode 自動微分

- ◆ Reverse-Mode の概念図はこうだった

$$\mathbb{R}^{n_N} \xleftarrow{u_N} \mathbb{R}^{n_{N-1}} \xleftarrow{u_{N-1}} \dots \xleftarrow{u_1} \mathbb{R}^{n_0} \xleftarrow{u_0} \mathbb{R}^0$$

$$\frac{du_N}{du_0} = \frac{\partial u_N}{\partial u_N} \frac{\partial u_N}{\partial u_{N-1}} \frac{\partial u_{N-1}}{\partial u_{N-2}} \dots \frac{\partial u_2}{\partial u_1} \frac{\partial u_1}{\partial u_0} \frac{\partial u_0}{\partial u_0}$$

 Reverse

- ◆ 問題：計算の入出力と逆順に辿る必要がある！
 - ▶ 微分係数の計算には関数の値そのものが必要、往復する必要がある
 - 機械学習で誤差逆伝播法 (back propagation) と呼ばれるもの
 - ▶ これを実現するためにいくつかやり方が知られている